

Línea de producción con balanceo dinámico de carga

Sistema distribuido que simula una planta conservera, detecta su cuello de botella en vivo y demuestra qué pasa cuando se escala la etapa lenta

César Olivares · Simón García-Huidobro

Profesor: Daniel Calderón R. · 26 de agosto de 2026

EL CASO

Una planta conservera ficticia de jurel en lata, con cuatro etapas en serie



- La unidad de trabajo es el **lote**; entre etapa y etapa hay una **cola**: la fila de lotes que esperan.
- Si a una etapa le llega trabajo más rápido de lo que procesa, su fila crece: eso es un **cuello de botella**.
- **Envasado**, la etapa más lenta, se replica detrás de un mecanismo de balanceo.


La pregunta del caso

¿Qué pasa con el cuello de botella cuando escalas la etapa lenta?

Adelanto: no desaparece — se muda.

ARQUITECTURA

Cinco servicios en tres nodos lógicos; cada nodo escala por un motivo distinto



- **Nodo B** es el único que se replica bajo carga: más capacidad = más contenedores ahí.
- **Nodo C** concentra el estado compartido, que no puede duplicarse sin coordinación.
- **Nodo A** escala con los usuarios, no con la producción. Separar nodos separa dominios de falla: si las estaciones saturan la CPU, el operador sigue atendido.

UNA IMAGEN, CUATRO ESTACIONES

El mismo programa, desplegado cuatro veces con configuración distinta

- Cada estación es **el mismo código**: la etapa, sus colas y su tiempo de ciclo llegan por variables de entorno (NOMBRE_ETAPA, COLA_ENTRADA, COLA_SALIDA, TIEMPO_CICLO).
- Ninguna réplica sabe cuántas hermanas tiene, ni necesita saberlo.
- Escalar la etapa replicada es **un solo comando**, sin tocar configuración.

```
docker compose up -d  
--scale envasado=3
```


1 imagen

4 etapas · hasta 6 contenedores de estación

BALANCEO POR DEMANDA

Las réplicas piden trabajo al quedar libres; nadie se los asigna

- El enunciado sugiere “réplicas detrás de un balanceador”. Nuestro balanceador **es la cola compartida**: el punto único por el que pasa el trabajo.
- Un round-robin es *estático*: le sigue enviando lotes a una réplica lenta o atascada.
- Con reparto por demanda, la réplica lenta simplemente **pide menos veces**: el balanceo dinámico emerge del mecanismo.



CONDICIÓN DE CARRERA

La provocamos antes de resolverla — ambas versiones están en el historial de commits

Ingenua: mirar y sacar (2 pasos)



duplicados con 3 réplicas y 200 órdenes

Atómica: BRPOP (1 operación)




0 duplicados en 200 órdenes

- Entre "mirar" (LRANGE) y "sacar" (LREM) hay una ventana en la que otra réplica ve la misma orden. La ensanchamos a propósito hasta reproducir duplicados.
- BRPOP extrae en **una operación indivisible**: la ventana no se administra con locks y TTL — **se elimina**.

CRITERIO DE CUELLO DE BOTELLA

Medimos espera, no servicio — y esa decisión es el corazón del proyecto

- En el supermercado: un cajero lento no es atasco; atasco es la **fila que crece** frente a su caja.
- Cuello = etapa con **mayor espera promedio** en una ventana móvil de 60 s, sobre umbrales relativos a su ciclo (advertencia $\geq 1,5\times$, crítico $\geq 3\times$).
- Con 2 réplicas, envasado sigue teniendo el ciclo más largo (12 s) — pero la fila crece en **esterilización**.



DEMO EN VIVO

El sistema completo, corriendo — tablero en localhost:8501

1. Línea al día: 4 etapas, 5 réplicas visibles con su ciclo y su carga.
2. Ingresamos lotes desde la interfaz, espaciados (~5 s).
3. La espera de esterilización crece en el gráfico: cartel **ámbar** → **rojo**, con la razón del diagnóstico.
4. **Condición de carrera en vivo**: el botón “Ejecutar la comparación” corre las dos versiones del reclamo — el mismo código de las estaciones — lado a lado: 300 envasados de 100 pedidos contra 100 de 100.
5. Matamos Redis: la interfaz **nombra al servicio caído** y el resto sigue vivo. Lo levantamos y todo continúa.

Qué mirar durante la demo


El color marca *importancia*, no identidad: lo normal es gris; el color fuerte queda reservado para advertencia y crítico, siempre con icono y texto.

1 comando

`docker compose up` — despliegue completo

EXPERIMENTOS: LA ARITMÉTICA DEL ESCENARIO


Inyección de 1 orden cada 5 s durante 180 s = 12 lotes/min



- Toda etapa **bajo la línea de llegada** acumula fila tarde o temprano.
- Con 2 réplicas, envasado sube a 10 lotes/min — mejor, pero aún insuficiente — y esterilización (8,6) queda como siguiente límite: la figura **anticipa los resultados**.

EL RESULTADO CENTRAL


La espera por etapa según réplicas de envasado — el cuello no se elimina: se muda



- Con 1 réplica, envasado acumula 67,8 s de espera; el resto de la línea, casi ociosa.
- Con 2, el cuello **se desplaza a esterilización**; con 3, envasado queda sobrado (0,7 s)... y el cuello sigue en esterilización.

¿CUÁNTO COMPRA CADA RÉPLICA?


Lead time: lo que tarda una orden desde que se crea hasta que sale terminada



- La segunda réplica compra un **21 %** de mejora; la tercera, casi nada: el límite ya no está en envasado.
- La siguiente inversión correcta sería **una segunda autoclave**, no una tercera envasadora — y el tablero lo responde en vivo.

BALANCEO CON UNA RÉPLICA LENTA


Dos réplicas normales + una al doble de ciclo, sobre la misma cola, 30 lotes



- Un round-robin habría repartido **10/10/10** sin importar la velocidad.
- El reparto **11/12/7** no lo programó nadie: emergió de que cada réplica pide trabajo solo al quedar libre.
- Eso es balanceo *dinámico*: proporcional a la capacidad real de cada una.

SATURACIÓN Y RECUPERACIÓN AUTOMÁTICA

Ráfaga de 25 órdenes de golpe, sonda a /metricas/cuello cada 15 s



- A los 32 s el sistema declara **crítico** solo; la congestión recorre la línea como una ola.
- A los **278 s** todo vuelve a normal **sin intervención**: las esperas viejas salieron de la ventana móvil.

MANEJO DE ERRORES

La interfaz nunca muestra un traceback: nombra al servicio que realmente falta

46 s

colgado con Redis caído
(el cuelgue estaba en el DNS, no
en el socket)

2,1 s

respuesta 503 con plazo duro de
2 s y mensaje en castellano

- 201 creación · 422 validación · 404 inexistente · 503 dependencia caída — verificados contra el sistema corriendo.
- El healthcheck mide *vida*, no dependencias: un servicio que responde 503 explicándose está sano.

PERSISTENCIA Y REPRODUCIBILIDAD

Dos tablas, nada guardado dos veces; despliegue con un comando

- SQLite en un volumen: ordenes y eventos (12 eventos por orden completa).
- Espera, servicio y lead time **no se almacenan**: se calculan siempre desde los eventos — el dato guardado dos veces es el dato que se contradice.
- La base sobrevive a `docker compose down` (verificado).

```
git clone <repo> && cd <dir>  
docker compose up -d --build  
# tablero en localhost:8501
```

8/8

contenedores *healthy* en la prueba de clon limpio

RESILIENCIA: CÓMO SE ABORDARÍA

No exigida por el enunciado — pero la arquitectura deja los puntos de corte listos

- **Estaciones:** sin estado propio, reconectan y mueren sin corromper nada. Pendiente: re-encolar el lote en curso si una réplica muere a mitad de ciclo (BLMOVE a una cola “en proceso” + barrendero de latidos vencidos).
- **Redis:** punto único de falla del reparto → Redis Sentinel, o un broker con confirmaciones (el bonus Kafka apuntaba ahí).
- **SQLite:** con más escritores o failover, migrar a MySQL/PostgreSQL cambiando solo el módulo `bd.py`.
- **APIs y UI:** sin estado; dos instancias tras un balanceador HTTP quedan en alta disponibilidad — los healthchecks ya existentes son su insumo.

Cada mejora toca **un** nodo sin rediseñar los demás: para eso era la división en nodos.

CONCLUSIONES

Todo lo afirmado está respaldado por mediciones reproducibles

El cuello no se elimina: se muda

De envasado a esterilización al pasar de 1 a 2 réplicas; la tercera ya casi no compra nada.

Medir espera es lo que permite verlo

El cuello real tenía un ciclo más corto que envasado; por servicio jamás se habría encontrado.

El balanceo dinámico emerge

11/12/7 con una réplica lenta, sin que nadie asignara ese reparto.

La carrera se elimina, no se administra

Extracción atómica: 0 duplicados en 200 órdenes, contra los duplicados de la versión ingenua.

Fallas explicadas, no enmascaradas

503 en 2,1 s nombrando al culpable real, en vez de 46 s de silencio.

Gracias — ¿preguntas?